Tugas Take Home GSLC Sesi 5
Advanced CNNs and Transfer Learning
Nama : Kenji Lawrence
NIM : 2802463440

A.ANALISIS KONSEPTUAL

A1. Efek Regularisasi pada Batch Normalization

Batch Normalization (BN) menormalkan aktivasi menggunakan mean dan variance yang dihitung dari mini-batch. Karena statistik setiap mini-batch dapat berbeda, aktivasi yang diterima lapisan berikutnya juga mengalami variasi kecil. Variasi ini dapat bertindak sebagai regularisasi ringan dan membantu model melakukan generalisasi. Namun, BN tidak selalu menggantikan Dropout. Pada batch berukuran sangat kecil, estimasi statistik dapat menjadi tidak stabil. BN juga dapat bermasalah apabila distribusi data saat training berbeda dari data saat inference. Oleh karena itu, penggunaan Dropout tetap dapat dipertimbangkan jika overfitting masih terjadi. Keputusan sebaiknya didasarkan pada hasil validasi, bukan anggapan bahwa BN selalu menghilangkan kebutuhan Dropout.

A2. Degradasi Jaringan Dalam dan Residual Connection

Pada plain CNN, penambahan lapisan dapat menyebabkan degradation problem, yaitu meningkatnya training error meskipun model lebih dalam secara teori dapat meniru fungsi model yang lebih dangkal. Residual connection membantu mengatasi kesulitan optimisasi ini dengan menghasilkan output $y = F(x) + x$, yaitu gabungan fungsi residual dan input asli. Ketika backpropagation berlangsung, gradien memiliki jalur langsung melalui koneksi identitas, sehingga tidak harus melewati seluruh transformasi berlapis. Jalur tersebut membantu mempertahankan aliran gradien dan mengurangi risiko vanishing gradient. Dengan demikian, residual connection memudahkan pelatihan jaringan yang lebih dalam, meskipun tidak menjamin seluruh masalah optimisasi dapat dihilangkan.

A3. Feature Extraction vs. Fine-Tuning

Feature extraction membekukan backbone pretrained dan hanya melatih classifier baru. Pendekatan ini membutuhkan lebih sedikit parameter yang diperbarui, memori gradien, dan komputasi. Metode ini cocok ketika data berlabel terbatas dan fitur dari ImageNet masih relevan. Sebaliknya, fine-tuning membuka sebagian atau seluruh lapisan backbone agar representasi dapat menyesuaikan domain target. Pendekatan ini berpotensi meningkatkan performa, tetapi meningkatkan biaya komputasi dan risiko overfitting atau destructive gradient updates. Untuk data terbatas, strategi praktisnya adalah memulai dengan feature extraction, lalu membuka blok terakhir secara bertahap jika performa validasi menunjukkan bahwa adaptasi tambahan diperlukan. Learning rate backbone sebaiknya lebih rendah daripada classifier.

A4. Kaidah Penerapan Data Augmentation

Data augmentation diterapkan pada train set untuk memperkaya variasi data dan membantu model menghadapi perubahan tampilan. Validation dan test set menggunakan transformasi deterministik agar evaluasi konsisten dan tidak dipengaruhi perubahan acak. Contoh transformasi yang tidak layak adalah rotasi ekstrem yang membuat citra hewan menjadi tidak realistis atau menghilangkan ciri visual penting. Transformasi harus mempertahankan semantic label invariance, yaitu mengubah tampilan citra tanpa mengubah makna labelnya. Jika transformasi merusak pola bulu, bentuk tubuh, atau karakteristik pembeda ras, proses augmentation justru dapat menyulitkan klasifikasi. Karena itu, jenis dan tingkat transformasi perlu disesuaikan dengan karakteristik dataset.

A5. Mitigasi Catastrophic Forgetting

Catastrophic forgetting terjadi ketika proses adaptasi model mengubah bobot pretrained secara berlebihan sehingga representasi yang sebelumnya dipelajari menjadi kurang berguna. Risiko ini meningkat ketika learning rate terlalu tinggi atau data target terlalu sedikit. Salah satu mitigasinya adalah differential learning rate, yaitu menggunakan learning rate lebih rendah untuk backbone dan lebih tinggi untuk classifier baru. Strategi ini membatasi perubahan fitur bawaan sekaligus memungkinkan classifier beradaptasi. Strategi kedua adalah gradual unfreezing, yaitu membuka lapisan backbone secara bertahap setelah classifier mulai stabil. Pendekatan tersebut mengurangi perubahan besar pada tahap awal training. Validation loss tetap perlu dipantau untuk menentukan apakah fine-tuning meningkatkan generalisasi atau justru menyebabkan overfitting.

C.LAPORAN EKSPERIMEN

1. Pendahuluan

Eksperimen ini bertujuan membandingkan strategi klasifikasi citra menggunakan Convolutional Neural Network pada kondisi data terbatas. Pengujian mencakup pelatihan ResNet-18 dari awal, feature extraction, progressive fine-tuning, kontrol penggunaan data augmentation, serta perbandingan dengan EfficientNet-B0. Hasil eksperimen digunakan untuk menilai trade-off antara performa, jumlah parameter yang dilatih, dan waktu komputasi.

2. Metodologi Eksperimen

Dataset yang digunakan adalah subset Oxford-IIIT Pet yang terdiri dari 10 kelas: Abyssinian, Bengal, Birman, Bombay, Persian, American Bulldog, Beagle, Boxer, Chihuahua, dan Pug. Total data berjumlah 996 citra dengan pembagian stratified menjadi 697 citra train, 149 validation, dan 150 test. Random seed yang digunakan untuk pembagian data adalah 42.

Input citra diubah menjadi ukuran 224 × 224 piksel dan dinormalisasi menggunakan mean serta standard deviation ImageNet. Konfigurasi utama menggunakan batch size 32, optimizer AdamW, CrossEntropyLoss, dan early stopping berdasarkan validation loss dengan patience 3 epoch.

Lima kondisi eksperimen yang diuji adalah:

- B1: ResNet-18 dengan inisialisasi bobot acak (from scratch).
- B2: ResNet-18 pretrained dengan backbone dibekukan dan hanya classifier yang dilatih.
- B3: ResNet-18 pretrained dengan layer4 dan classifier dibuka untuk fine-tuning.
- B4: Kontrol augmentation menggunakan konfigurasi feature extraction tanpa augmentation.
- B5: EfficientNet-B0 pretrained dengan feature extraction.

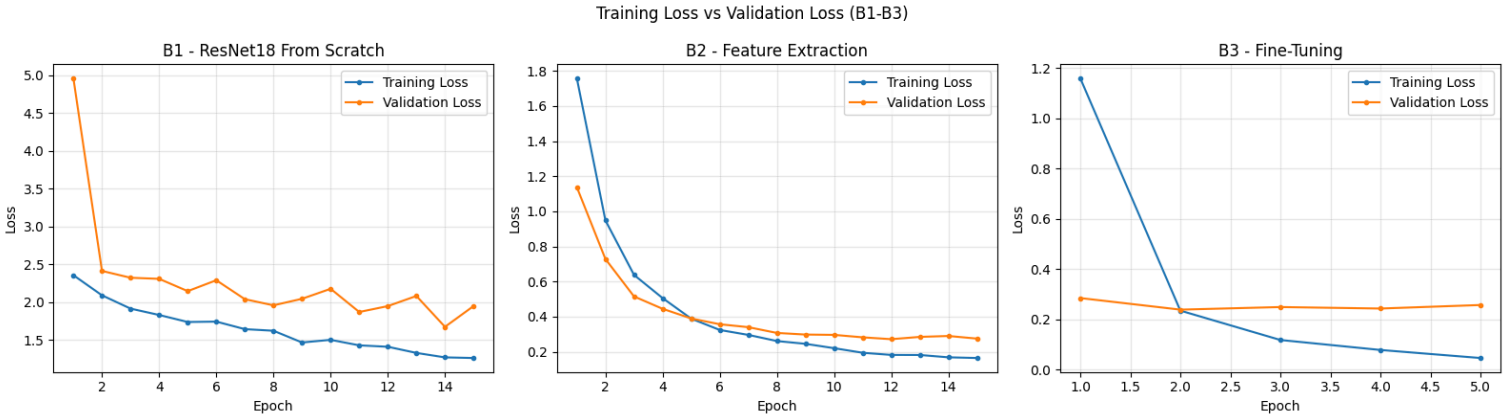
3. Hasil Eksperimen

Tabel 1. Perbandingan hasil eksperimen B1–B5

Kondisi	Strategi	Trainable parameters	Learning rate	Epoch terbaik	Durasi (detik)	Validation accuracy	Test Macro F1
B1	ResNet-18 scratch	11.181.642	1e-3	14	135,54	46,98%	37,21%
B2	Feature extraction	5.130	1e-3	12	118,44	92,62%	90,61%
B3	Fine-tuning layer4 + fc	8.398.858	layer4: 1e-4; fc: 1e-3	2	40,56	93,29%	91,93%
B4	Feature extraction tanpa augmentation	5.130	1e-3	15	88,99	90,60%	92,62%
B5	EfficientNet-B0	12.810	1e-3	14	120,84	93,29%	90,08%

	feature extraction						

Gambar 1. Kurva Training Loss dan Validation Loss B1–B3.



4. Analisis Komparatif

4.1 From Scratch vs. Transfer Learning

B1 memperoleh test Macro F1 sebesar 37,21%, sedangkan B2 mencapai 90,61%. Perbedaan ini menunjukkan bahwa bobot pretrained memberikan keuntungan besar pada dataset yang relatif terbatas. Model from scratch harus mempelajari fitur visual dari awal, sedangkan transfer learning memanfaatkan representasi yang telah dipelajari dari ImageNet. Hasil ini mendukung penggunaan pretrained model sebagai baseline untuk klasifikasi citra dengan data terbatas.

4.2 Feature Extraction vs. Fine-Tuning

B3 menghasilkan test Macro F1 sebesar 91,93%, lebih tinggi sekitar 1,32 poin persentase dibanding B2. Membuka layer4 memungkinkan fitur tingkat tinggi menyesuaikan diri dengan karakteristik ras hewan. Namun, jumlah parameter yang dilatih meningkat dari 5.130 menjadi 8.398.858. B2 lebih sederhana dan cocok untuk keterbatasan komputasi, sedangkan B3 dapat dipertimbangkan ketika peningkatan performa diperlukan. B3 mencapai validation loss terbaik pada epoch ke-2 dan dihentikan lebih awal. Hasil ini menunjukkan bahwa adaptasi tambahan dapat membantu, tetapi tetap perlu dikontrol menggunakan validation loss.

4.3 Pengaruh Data Augmentation

B4 memperoleh test Macro F1 sebesar 92,62%, sedangkan B2 mencapai 90,61%. Pada eksperimen ini, konfigurasi tanpa augmentation memperoleh skor lebih tinggi. Namun, satu eksperimen belum cukup untuk menyimpulkan bahwa augmentation selalu merugikan. Efeknya dapat dipengaruhi ukuran dataset, jenis transformasi, dan variasi data. Perbandingan perlu mempertimbangkan validation loss dan kesenjangan performa train-validation, bukan hanya skor test.

4.4 Perbandingan EfficientNet-B0

B5 memperoleh validation accuracy sebesar 93,29% pada epoch ke-14, dengan validation loss sebesar 0,3174 dan durasi training sekitar 120,84 detik. Test Macro F1 yang diperoleh adalah 90,08%. Hasil ini menunjukkan bahwa model memiliki performa validasi yang baik, tetapi skor test Macro F1 masih lebih rendah dibandingkan B3 dan B4. Perbedaan antara hasil validasi dan pengujian perlu diperhatikan ketika memilih model untuk penggunaan lebih lanjut. Perbandingan ini belum dapat menentukan keunggulan arsitektur secara umum karena konfigurasi pelatihan B5 berbeda dari B3.

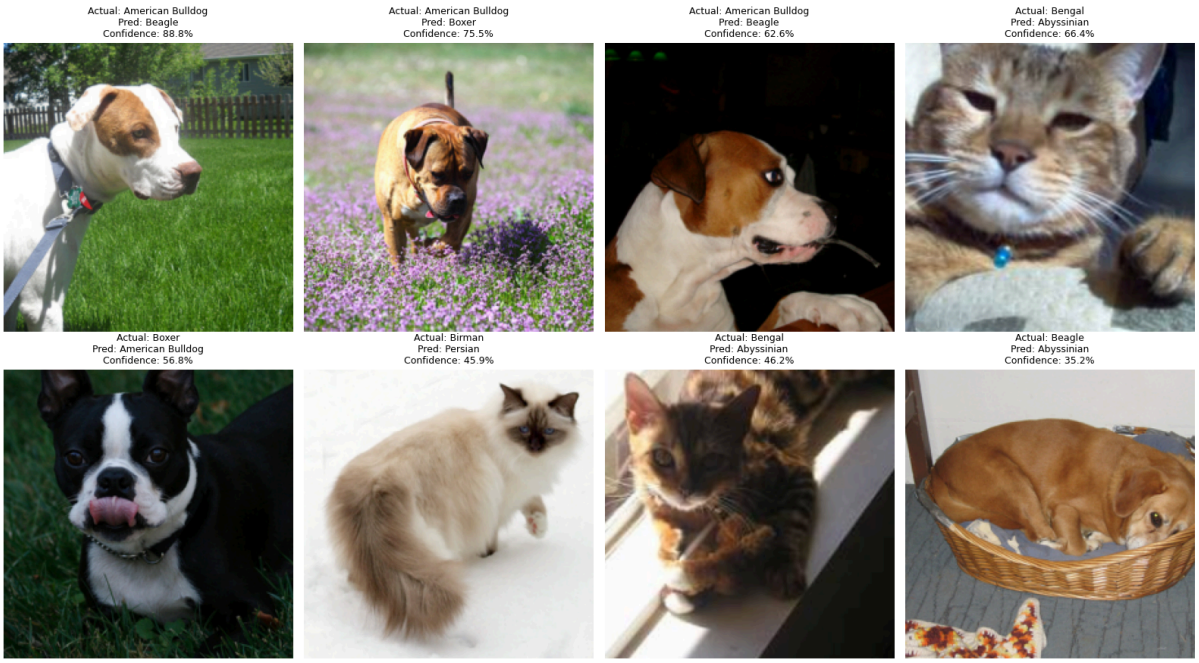
5. Failure Analysis

Bagian ini menampilkan delapan misklasifikasi yang tercatat pada file failure analysis. Confidence merupakan probabilitas untuk kelas yang diprediksi, bukan jaminan bahwa prediksi tersebut benar.

Tabel 2. Ringkasan misklasifikasi

No.	Label aktual	Prediksi	Confidence
1	American Bulldog	Beagle	88,77%
2	American Bulldog	Boxer	75,50%
3	American Bulldog	Beagle	62,57%
4	Bengal	Abyssinian	66,39%
5	Boxer	American Bulldog	56,79%
6	Birman	Persian	45,89%
7	Bengal	Abyssinian	46,22%
8	Beagle	Abyssinian	35,23%

Gambar 2. Contoh misklasifikasi



Contoh gambar 2 nomor 1

Label aktual: American Bulldog

- Prediksi: Beagle
- Confidence: 88,77%
- Hipotesis penyebab: Periksa kemiripan ciri wajah, sudut pengambilan gambar, pencahayaan, atau latar belakang.

Gunakan format yang sama untuk tujuh gambar lainnya dan sesuaikan dengan data pada Tabel 2. Pastikan gambar berasal dari test set dan benar-benar cocok dengan label serta prediksi yang dicantumkan.

Beberapa kesalahan terjadi pada ras yang memiliki kemiripan visual, seperti American Bulldog dan Boxer. Kesalahan Bengal menjadi Abyssinian juga perlu diperiksa berdasarkan pola bulu dan karakteristik visual pada citra. Birman yang diprediksi sebagai Persian mungkin berkaitan dengan kemiripan warna atau bentuk bulu. Penjelasan tersebut merupakan hipotesis awal yang perlu diverifikasi melalui pemeriksaan gambar asli.

6. Rekomendasi Rekayasa dan Limitasi

Untuk penggunaan awal dengan data terbatas, B2 merupakan baseline yang efisien karena hanya melatih 5.130 parameter dan menghasilkan test Macro F1 sebesar 90,61%. Apabila peningkatan performa diperlukan, B3 dapat dipertimbangkan karena mencapai 91,93%. B4 mencatat skor tertinggi dalam eksperimen ini, yaitu 92,62%, dan layak diuji lebih lanjut sebelum dipilih sebagai konfigurasi produksi.

Eksperimen ini memiliki beberapa keterbatasan. Pengujian hanya menggunakan satu seed dan satu pembagian dataset, jumlah data relatif kecil, serta hanya mencakup 10 kelas.

Evaluasi juga belum menunjukkan variasi performa antar-seed atau interval kepercayaan. Selain itu, perbandingan arsitektur dilakukan dengan konfigurasi pelatihan yang berbeda. Karena itu, hasil ini belum dapat dianggap sebagai jaminan performa pada distribusi data produksi.

7. Kesimpulan

Transfer learning memberikan peningkatan performa yang besar dibandingkan pelatihan ResNet-18 dari awal pada dataset yang diuji. B3 menunjukkan peningkatan Macro F1 dibanding B2, sedangkan B4 memperoleh skor Macro F1 test tertinggi di antara konfigurasi yang tercatat. B5 menghasilkan validation accuracy yang tinggi, tetapi test Macro F1 masih berada di bawah B2, B3, dan B4. Keputusan akhir perlu mempertimbangkan biaya komputasi, konsistensi evaluasi, dan hasil pengujian lanjutan. Pengujian dengan beberapa seed dan analisis kesalahan per kelas dapat membantu memastikan apakah peningkatan tersebut stabil.

8. Referensi

1. He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR.
2. Yosinski, J., Clune, J., Bengio, Y., & Lipson, A. (2014). *How transferable are features in deep neural networks?* NeurIPS.
3. Parkhi, O. M., Vedaldi, A., Zisserman, A., & Jawahar, C. V. (2012). *Cats and Dogs*. CVPR.
4. PyTorch Contributors. *Torchvision Models Documentation*. https://pytorch.org/vision/stable/models/

9. Pernyataan Penggunaan AI

ChatGPT digunakan sebagai alat bantu untuk memahami konsep, menyusun struktur laporan, dan membantu merangkum metrik dari log eksperimen. Angka hasil eksperimen merujuk pada notebook dan file log yang tersedia. Kebenaran angka, implementasi kode, serta interpretasi hasil perlu diverifikasi secara mandiri. Hipotesis penyebab misklasifikasi juga perlu diperiksa dengan melihat citra aslinya.